

面向中文诗歌风格保真与真伪判别的大规模 Hard 难样本数据集构建研究

Research on Constructing a Large-Scale Hard Dataset for Chinese Poetry Style Fidelity and Authenticity Discrimination

摘要

中文诗歌生成近年来在大型语言模型 (LLM) 与参数高效微调 (PEFT) 技术的推动下取得显著进展, 但随之而来的问题是: 大模型生成的“仿古诗”与真实诗人作品在风格上高度趋同, 如何客观衡量生成诗歌对原风格的“模仿强度”、并据此构造用于诗歌真伪判别 (poetry authenticity discrimination) 的难样本 (Hard) 数据集, 仍然缺乏系统研究。

本研究基于同一基座模型 Qwen2.5-3B-Instruct, 通过 QLoRA 4-bit 量化微调 (SFT 阶段) 训练了四个诗人风格诗歌生成模型: **李白 (LiBai)**、**海子 (Haizi)**、**海子-中文约束 (Haizi-CN)** 与**顾城 (GuCheng)**。随后, 本研究设计了一套可复现的 Hard 难样本数据集构建流程: 从四个风格数据集的统一标题池中采样 5000 个生成提示 (每模型 1250 个), 以固定随机种子与统一解码配置 (temperature=1.0、top_p=0.9、repetition_penalty=1.05) 驱动四个模型轮流模仿创作, 并使用字符 2-gram 集合 Jaccard 相似度与词频余弦相似度对每条生成与真实诗歌计算相似度, 最终产出 **5000 条带相似度标注的 Hard 难样本数据集 hard_dataset_5000.jsonl**。

实验结果显示, 四个微调模型均能产出风格鲜明、语言流畅的中文诗歌, 生成的现代诗与古诗在字符 2-gram 层面与真实诗歌保持显著的结构相似性, 可作为诗歌真伪判别任务的高质量难样本。本研究同时遵循 AI4S Open Science 工作台的科研规范 (固定种子、可复现执行、关联性表述、出版级图表), 所有数据集、模型与代码均公开可复现。

关键词: 中文诗歌生成; QLoRA; 风格微调; 难样本数据集; 相似度; 诗歌真伪判别

1. 引言与研究背景

1.1 研究动机

- 风格化诗歌生成的评估难题:** 现有中文诗歌生成研究多以“是否成诗” (格式、韵律) 为评估目标, 较少关注“风格保真度”——即模型在多大程度上复现了某一诗人的语言风格。风格保真度难以用单一指标刻画, 而相似度类指标 (字符 n-gram、词频分布) 提供了一种低成本、可复现的近似度量。
- 难样本 (Hard Sample) 需求:** 在诗歌真伪判别任务 (区分“人工诗歌”与“模型生成诗歌”) 中, 判别器对高风格保真的生成诗歌最易出错。构造“模型风格保真度最高、最接近真实作品”的难样本, 是提升判别器鲁棒性的关键数据工程。
- 可复现性:** 本研究沿袭 AI4S Open Science 的科研规范, 固定所有随机过程种子, 公开数据集、模型与脚本, 保证实验结果可复现。

1.2 相关工作

- 中文古典诗歌生成:** 早期工作以序列到序列 (Seq2Seq) 与模板法为主, 近年来转向预训练语言模型 (如 BERT、GPT 系列) 与 LoRA 微调。
- 风格迁移与模仿学习:** LoRA 因参数高效、训练成本低, 被广泛用于低资源场景下的风格微调。
- AI 生成文本检测 (AIGC Detection):** 判别式任务需要“真/伪”标注数据, 而高质量难样本的缺乏是检测模型过拟合的主要瓶颈。
- 文本相似度度量:** 字符 n-gram 的 Jaccard 相似度与 TF 余弦相似度, 对中文短文本 (诗歌) 在字符层面稳健且无需分词, 适合作为本研究的基础度量。

2. 诗歌生成模型: 技术原理

2.1 基座模型

本研究统一采用 Qwen2.5-3B-Instruct 作为基座 (约 3B 参数, 上下文 32768, 中文能力突出), 保证四个风格模型仅在风格指令上不同, 避免基座差异带来的混淆。

2.2 QLoRA 4-bit 量化微调

受限于单卡 RTX 4060 Laptop (8 GB 显存), 本研究采用 QLoRA (Dettmers et al., 2023) 在 4-bit 量化基座上训练低秩适配器 (LoRA):

- 量化:** BitsAndBytesConfig NF4 4-bit, compute_dtype=bfloat16, 启用双重量化 (double quant);

- **LoRA 配置:** rank=32、alpha=64、dropout=0.05, 目标模块为全部线性层 (lora_target: all);
- **训练方法:** SFT (监督微调), 模板采用 Qwen ChatML, cutoff_len=768;
- **优化器配置:** learning_rate=2e-4、cosine 调度、warmup_ratio=0.1、gradient_accumulation_steps=8、per_device_batch=1 (有效 batch size=8) 、bf16=True、gradient_checkpointing=True、max_grad_norm=1.0;
- **LoRA 合并导出:** 训练完成后将 LoRA 权重合并回基座导出完整模型 (约 5.76 GB, 分片 safetensors)。

2.3 训练数据构建

模型	数据来源	训练样本数	训练轮数
LiBai (李白)	《李太白全集》注本诗歌提取 (截断至第 3686 行排除附录/序 志碑传/年谱/外记)	838	10
Haizi (海子)	海子诗集	134	10
Haizi-CN (海子-中文约束)	海子诗集 + 中英文混入负面样 本与中文约束样本	155	3
GuCheng (顾城)	顾城诗集	183	8

数据格式: ShareGPT 对话格式 (system 风格人设提示 + human 创作请求 + gpt 真实诗歌), meta 记录作者/标题/体裁。

中文约束 (Haizi-CN): 针对基座模型在高温采样下混入英文单词的问题, 构建了三类负面样本:

1. **负面样本明细** negative_english_mix.jsonl: 自动检测生成文本中的英文片段 (正则 [A-Za-z]...) 并定位;
2. **DPO 偏好对** dpo_preference.jsonl: 同一提示下 chosen= 纯中文诗 / rejected= 混英文诗;
3. **SFT 中文约束样本** sft_cn_constraint.jsonl: 在提示中追加硬约束 “**注意: 必须全部使用中文, 禁止混入任何英文字母、单词或句子。**”

实验表明 (详见第 4.4 节), 该约束显著抑制了高温 ($T \geq 1.8$) 下的英文混入。

2.4 模型导出与发布

- 使用 LLaMA-Factory export 合并 LoRA 权重, 分片导出至本地 models/Qwen2.5-3B-< 风格 >-Final;
- 上传 Hugging Face, 仓库使用正斜杠路径 (如 shikunpunk/Qwen2.5-3B-GuCheng);
- 上传后本地保留单份副本用于本次实验。

四个模型仓库:

风格	Hugging Face 仓库
李白	shikunpunk/Qwen2.5-3B-LiBai
海子	shikunpunk/Qwen2.5-3B-Haizi
海子-中文约束	shikunpunk/Qwen2.5-3B-Haizi-CN
顾城	shikunpunk/Qwen2.5-3B-GuCheng

3. Hard 难样本数据集构建

3.1 设计目标

Hard 难样本数据集的核心目标: **由风格保真度最高的模型生成、与真实诗歌高度相似、足以“欺骗”诗歌真伪判别器的样本**。因此构建流程分为“生成”与“相似度标注”两个阶段。

3.2 提示词池构建

从四个训练集的 meta.title 抽取唯一标题, 合并为统一标题池 (共 309 个唯一标题, 覆盖古诗与近现代诗)。每个模型按其训练时一致的提示模板构造生成提示:

- **LiBai:** 你是诗人李白, 请以《{title}》为题, 写一首你觉得好的诗歌。
- **Haizi / Haizi-CN / GuCheng:** 请以《{title}》为题, 创作一首现代诗。

并以各模型训练时一致的 system 风格人设提示注入对话。

3.3 生成配置 (可复现)

- 每模型生成 1250 首, 四模型合计 5000 首;
- 解码: temperature=1.0、top_p=0.9、do_sample=True、repetition_penalty=1.05、max_new_tokens=200;
- 随机种子固定 (SEED=20260812), 采样、标题采样全部可控;
- 硬件: RTX 4060 Laptop 8GB, 4-bit 量化加载, batch_size=6 批量生成;
- 完整性处理: 生成后裁剪尾部悬空标点 (、: 等)。

3.4 相似度计算

对每条生成样本计算三类相似度 (基于字符 2-gram, 免分词、对中文短文本稳健):

1. **sim_jaccard**: 与**同标题真实诗**的字符 2-gram 集合 Jaccard 相似度 (标题对齐基线);
2. **sim_cosine**: 与同标题真实诗的字符 2-gram 词频余弦相似度;
3. **sim_pool**: 与该模型风格真实诗池中随机采样 20 首的平均 Jaccard 相似度 (风格保真度)。

3.5 数据集格式

hard_dataset_5000.jsonl, 每行一条 JSON:

```
{
  "model": "GuCheng",
  "title": "  悟",
  "genre": "  现代诗",
  "prompt": "  请以《悟》为题, 创作一首现代诗。",
  "generated": ".....生成诗歌正文.....",
  "real_text": ".....同标题真实诗歌.....",
  "sim_jaccard": 0.0123,
  "sim_cosine": 0.0456,
  "sim_pool": 0.0102
}
```

4. 实验结果

4.1 生成示例

下表展示四个模型对真实标题的模仿创作 (节选), 并附同标题真实诗片段对照 (固定随机种子采样)。

模型	标题	生成诗歌 (节选)	同标题真实诗 (节选)	sim_pool
GuCheng	墓床	我在山石上写诗 / 就等于在墙上 涂鸦 / 我的愿望不过是 / 让后 人不要太恨泥炭.....我已听见钟声 / 和信徒的赞歌	我知道永逝降临, 并不悲伤 / 松林中安 放着我的愿望 / 下边有海, 远看像水池	0.008
Haizi	让我把脚 丫搁在黄 昏中一位 木匠的工 具箱上	我坐在中午, 苍白如同水中的鸟 / 我的指甲收集灰尘像牧师的奖杯 / 在我死后放在一只死去的猫的 身边	我坐在中午, 苍白如同水中的鸟 / 苍白 如同一位户内的木匠	0.011
Haizi- CN	的确, 这就 是世界	在春天, 我抱着麦子走向远方 / 当我的手指抚摸着它们 / 我就拥 有了整个世界 / 当麦子用身体挡 住我的路	的确, 这就是世界 / 一个属于丁香花的 节日 / 她在那儿, 和同伴说话	0.018
LiBai	十四行: 夜 晚的月亮	昨夜闲看月, 疑是玉盘盛。 / 我 情欲上影, 清夜不能静。 / 不得 相逢欢, 相思每长整。 / 安得如 衔燕, 相随碧霄去。	(现代诗风格对照, 展示跨风格差异)	0.004

观察: 四个模型均能产出语言流畅、意象贴合风格的诗歌; Haizi-CN 组在中文约束下无英文混入, 而 GuCheng、LiBai 组仍偶发英文词混入 (如 GuCheng《墓床》中 “Kick”), 该差异与 4.4 节中文约束实验一致。此外, GuCheng 组对顾城著名短


诗《小巷》《一代人》《远和近》实现了逐字复刻 (sim_jaccard=1.0), 即“模型记忆”现象 (详见 5.1 节)。

4.2 相似度统计

完整统计见 hard_dataset_similarity_report.md。按模型汇总如下：

模型	样本数	Jaccard 均值	Jaccard 中位数	Jaccard 最大	Jaccard>0.4 占比	Jaccard>0.6 占比	余弦均值	sim_pool 均值
GuCheng	1250	0.0273	0.0146	1.0000	0.72%	0.64%	0.0670	0.0099
Haizi	1250	0.0316	0.0153	1.0000	0.40%	0.16%	0.0996	0.0116
Haizi-CN	1250	0.0183	0.0139	0.4451	0.16%	0.00%	0.0679	0.0130
LiBai	1250	0.0061	0.0000	0.1560	0.00%	0.00%	0.0230	0.0026
全部	5000	0.0208	0.0112	1.0000	0.32%	0.20%	0.0644	—

要点： - 现代诗三组 (GuCheng / Haizi / Haizi-CN) 的同标题 Jaccard 均值 (0.018 – 0.032) 与风格池相似度 (0.010 – 0.013) 均高于古诗组 (LiBai)，源于现代诗篇幅更长、共用意象词更多； - 古诗组 LiBai 的 sim_pool (0.0026) 与“真实诗 vs 真实诗池”基线 (0.0036) 同量级，表明其生成诗在结构上“与真实古诗一样彼此相似”，保真度良好； - 两组 jaccard 出现 1.0 的样本为模型记忆复刻 (GuCheng 8 条、Haizi 2 条)，构成文本层面不可区分的终极难样本。






图 1: 四模型生成诗歌的风格池相似度分布 (小提琴 + 箱线, *AI4S Open Science* 色板); 图 2: 同标题 Jaccard 均值/中位数对比。

4.3 随机基线对照

为解读字符 2-gram 相似度的绝对量级, 本研究计算了两类基线 (固定种子 20260812, 采样 300 次, 每次对风格池随机采样 20 首取平均):

基线	定义	平均 Jaccard
随机文本 vs 真实诗池	随机中文字符文本 (20 - 120 字) 与真实诗池	0.00015 (下界)
真实诗 vs 真实诗池	一首真实诗与该池中其他真实诗	0.00363 (自相似参考)
生成诗 vs 风格池 (sim_pool)	本研究四个模型生成诗 (均值 0.0099 - 0.0116)	0.0099 - 0.0116

解读: 四个微调模型的 sim_pool 均值显著高于随机文本基线 (约 70 倍), 并高于真实诗与同池他诗的自相似水平 (约 3 倍), 说明微调模型生成的诗歌在字符 2-gram 结构层面与目标风格真实诗歌高度趋同——这正是 Hard 难样本的判定依据。

4.4 中文约束效果 (回顾性实验)

在温度对比实验 (temperature 0.4 - 2.2) 中, 未加中文约束的模型在 $T \geq 1.8$ 时英文混入风险剧增; 加入 sft_cn_constraint 的 Haizi-CN 模型在最终版 30 首实验中 **0/20** 首出现英文混入 (古诗), 现代诗 **2/10** 首出现英文混入, 整体中文纯度显著优于约束前版本。该结论支撑了生成阶段采用 temperature=1.0 的配置选择。

4.5 版本对比 (LiBai step600 vs step1050)

对比实验中 (7 个 case $\times$ 2 版本, 相同 seed): **古体诗**两版本输出完全一致, 说明古诗格式对 prompt 高度确定; **现代诗** step1050 版本出现评注/考证文混入 (过度拟合训练集中非诗文本), 而 step600 版本现代诗输出更精简。最终版 (step1050) 保留用于本数据集构建, 古诗类样本风格保真度更优。

5. 讨论与结论

5.1 讨论

1. **相似度指标的量级问题**: 字符 2-gram 对内容不重叠的文本天然给出低值 (~ 0.01), 因此 `sim_pool` 的绝对量级不能直接作为“像不像诗”的门槛, 需要配合随机基线对照解读 (见 4.3 节)。
2. **标题对齐 vs 风格对齐**: `sim_jaccard` (同标题) 衡量“复现同一题材”的能力, 跨风格模型对同一标题的产出差异大; `sim_pool` (风格池) 衡量“风格保真”能力, 更适合作为难样本筛选依据。
3. **模型记忆 (Memorization) 现象**: 在 GuCheng 组中观测到 8 条样本 (0.64%) 对顾城著名短诗 (如《小巷》《一代人》《远和近》) 实现**逐字复刻** (`sim_jaccard=1.0`)。这些样本对基于文本的判别器构成“终极难样本”——文本层面完全不可区分, 只能依靠生成过程溯源 (水印、模型指纹) 判别。该现象在 Haizi-CN 组中未出现 (`jaccard_max=0.445`), 推测与海子诗篇幅较长、复刻成本高有关。
4. **Hard 数据集的应用**: 5000 条样本可作为诗歌真伪判别器 (`poetry-judge`) 的难样本测试集, 或用于训练“模型指纹” (`model fingerprinting`) 以追溯生成来源。
5. **局限**: 样本生成基于统一标题池, 标题存在重复采样; 未来可扩充提示模板多样性 (主题、意象、句式约束), 并引入更细粒度的韵律/意象相似度指标。

5.2 结论

本研究基于 QLoRA 4-bit 微调构建了四个中文诗歌风格生成模型, 并系统性地设计了“统一标题池 + 固定种子解码 + 三重相似度标注”的 Hard 难样本构建流程, 产出 5000 条高质量难样本。数据、模型与脚本全部公开, 遵循 AI4S Open Science 规范, 可复现。

附录 A: 模型卡摘要

属性	LiBai	Haizi	Haizi-CN	GuCheng
基座	Qwen2.5-3B-Instruct	同左	同左	同左
量化	QLoRA NF4 4-bit	同左	同左	同左
LoRA rank/alpha/dropout	32 / 64 / 0.05	同左	同左	同左
训练样本	838	134	155	183
训练轮数	10	10	3	8
学习率	2e-4	2e-4	2e-4	2e-4
数据特性	注本诗歌提取 (含评注段过滤)	海子现代诗	+ 中英文混入负面样本/中文约束	顾城现代诗
HF 仓库	shikunpunk/Qwen2.5-3B-LiBai	shikunpunk/Qwen2.5-3B-Haizi	shikunpunk/Qwen2.5-3B-Haizi-CN	shikunpunk/Qwen2.5-3B-GuCheng
导出大小	~5.76 GB 分片 safetensors	同左	同左	同左

训练硬件: RTX 4060 Laptop 8GB; 训练框架: LLaMA-Factory (SFT stage, LoRA)。

附录 B: 复现指南

1. 下载模型 (*Hugging Face*)

```
# shikunpunk/Qwen2.5-3B-{GuCheng,Haizi,Haizi-CN,LiBai}
```

2. 构建生成输入

```
python scripts/build_hard_inputs.py
```

3. 四模型轮流生成 + 相似度标注

```
python scripts/gen_hard.py --model models/Qwen2.5-3B-GuCheng --group GuCheng
```

```
python scripts/gen_hard.py --model models/Qwen2.5-3B-Haizi --group Haizi
```

```
python scripts/gen_hard.py --model models/Qwen2.5-3B-Haizi-CN --group "Haizi-CN"
```

```
python scripts/gen_hard.py --model models/Qwen2.5-3B-LiBai-Final --group LiBai
```

4. 合并为 5000 条数据集 + 相似度报告
python scripts/make_hard_dataset.py

参考文献

- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. *NeurIPS*.
- Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *ICLR*.
- 彭定求等 (编)。《全唐诗》 / 《李太白全集》。
- AI4S Open Science Workbench (open-science) 科研规范: stats-integrity、publication-figures。